



UNIVERSIDAD DE BURGOS
ESCUELA POLITÉCNICA SUPERIOR
Máster en Ingeniería Biomédica



TFM del Máster en Ingeniería Biomédica

**Reposicionamiento de Fármacos mediante Medicina
de Redes
Documentación Técnica**

Presentado por Nisrine Fariss Lamine

11 de junio de 2026

**Tutores: José Ignacio Santos Martín - Virginia
Ahedo García**

Plan de Proyecto Software	3
Introducción	3
Planificación temporal	3
Planificación económica	4
Coste de Personal.....	4
Coste Técnico.....	4
Viabilidad Legal.....	4
Documentación de Usuario.....	4
Requisitos Software y Hardware para Ejecutar el proyecto.....	4
Instalación.....	5
Demostraciones prácticas.....	5
Búsqueda por enfermedad.....	5
Búsqueda por fármaco	7
Búsqueda por proteína o gen aislado	9
Pestaña de información y calidad de los datos	10
Manual del Programador	11
Estructura de directorios	11
Entorno de desarrollo.....	12
Despliegue de la Aplicación.....	13
Pruebas del sistema.....	14
Instrucciones para la modificación o mejora del proyecto.....	14
Implementación del Modelado de Efectos Combinados.....	14
Integración de Redes Específicas por Tejido	14
Validación Externa con Conjuntos de Reposicionamiento Conocidos.....	14
Descripción de adquisición y tratamiento de datos	15
Descripción formal de los datos	15
Especificación de diseño.....	16
Actores y Componentes de la Interfaz	17
Capa de Lógica y Algoritmos.....	17
Capa de Datos	17
Componentes Visuales.....	17
Referencias.....	18

Plan de Proyecto Software

Introducción

Para garantizar el correcto desarrollo de la plataforma de reposicionamiento de fármacos se ha seguido una metodología ágil apoyada en una planificación temporal y económica. Este anexo desglosa la gestión de los plazos técnicos, los costes asociados al personal y recursos de hardware, así como el marco regulatorio y de propiedad intelectual que garantizan la viabilidad legal del proyecto.

Planificación temporal

El control y seguimiento del avance del proyecto se gestionó centralizadamente a través de un repositorio en *GitHub*. Las unidades funcionales se desglosaron en tareas (*issues*) etiquetadas por tipología y agrupadas de manera secuencial en hitos cronológicos (*milestones*):

- **Investigación de bases de datos:** en este *milestone* lo que se buscaba era obtener el conjunto de datos necesarios para la implementación de la web. Se trata de la consolidación del interactoma proteico, mediante la extracción de datos moleculares de la base de datos *BioGRID*, la asignación fármaco-diana de *DrugBank* y el mapeo asíncrono *UniProt* para las asociaciones de patologías.
- **Diseño e implementación de la aplicación en Streamlit:** en este apartado se agrupan las *issues* del desarrollo de la plataforma. Cada *issue* representa una pestaña de la web en la que se iban dejando comentarios de los avances que se realizaban o el contenido que iba a tener dicha página. Aparte, se encuentra otra *issue* "nueva función" en la que se solucionaba la programación del algoritmo de búsqueda en anchura multi-fuente y desarrollo matemático del modelo nulo con las permutaciones de Monte Carlo.
- **Documentación, memoria y anexos:** este bloque como su propio nombre dice, se encargaba de agrupar los capítulos de la memoria que cada uno de ellos consistía en un *issue*. También engloba la redacción de los anexos.




Figura 1 Algunas tareas del repositorio

Planificación económica

Se analiza el presupuesto estimado para la realización del proyecto en un escenario profesional real, considerando los recursos humanos y técnicos empleados.

Coste de Personal

El desarrollo ha sido ejecutado por una única ingeniera biomédica júnior durante un período de 3 meses. Tomando como base un salario bruto mensual de referencia de 1.700 € (1) para un graduado, al que se añaden las cotizaciones sociales a cargo de la empresa (32,15%) se detalla a continuación:

Concepto	Cantidad
Salario mensual bruto	1700€
Cotizaciones sociales empresa	546,55€
Total (3 meses)	8986.2€

Tabla 1 Cálculo del coste total del personal

Coste Técnico

Todo el software empleado es de acceso abierto, por lo que no supuso ningún coste.

En el caso de equipos externos, no se ha necesitado más que un ordenador portátil de la marca Lenovo, modelo exacto Lenovo Ideapad Slim 3 con un precio estimado de 624,49 euros, al que se le estima hasta 7 años de vida con buen mantenimiento y cuidado. El coste imputado por amortización en 3 meses es de 22,30€.

Viabilidad Legal

Al llevar a cabo este proyecto tecnológico, resulta imprescindible evaluar su viabilidad legal, no solo para proteger tanto el proceso como los derechos de propiedad intelectual, sino también para asegurar el cumplimiento de la normativa vigente actual.

La viabilidad legal de la aplicación está plenamente garantizada. La plataforma no recopila, procesa ni almacena datos de carácter personal de los usuarios, limitando sus operaciones a consultas analíticas indexadas por identificadores moleculares anonimizados (IDs de genes o nombres de fármacos), quedando completamente fuera del ámbito de aplicación del Reglamento General de Protección de Datos (RGPD).

Toda la información biológica proviene de repositorios científicos públicos internacionales de libre acceso autorizados para fines académicos de investigación traslacional. En materia de propiedad intelectual, el código fuente original está protegido bajo el Real Decreto Legislativo 1/1996 de la Ley de Propiedad Intelectual (3) y se aloja en un repositorio público sin fines comerciales.

Documentación de Usuario

Requisitos Software y Hardware para Ejecutar el proyecto

La aplicación ha sido diseñada como una herramienta web de fácil acceso, cuyo objetivo final es el uso del público en general, siendo estos desde desarrolladores para las mejoras futuras de la aplicación o por profesionales para nuevas alternativas de fármacos.

No requiere ningún hardware especializado ni requisitos especiales para su puesta en marcha. Su acceso puede ser desde cualquier navegador moderno como Google Chrome, ampliamente usado por la población en general, ya sea desde un ordenador personal o un dispositivo móvil.

Instalación

Al ser una aplicación web, no requiere ninguna instalación, el usuario puede acceder a la [URL](#) de la aplicación. Una vez cargada la interfaz, se podrá empezar a interactuar con las diferentes pestañas visibles desde la barra del navegador.

Durante la ejecución de cada pestaña la visualización de las subredes puede demorarse un tiempo debido a que introducen un coste computacional elevado.

Demostraciones prácticas

La aplicación web se estructura en un panel interactivo lateral de control y cuatro pestañas operacionales. Las ejecuciones prácticas de cada módulo se detallan a continuación.

Al iniciar la aplicación, el usuario visualiza una barra lateral que actúa como un descargo de responsabilidad analítico, recordando que las distancias calculadas establecen hipótesis de reposicionamiento *in silico* y no indicaciones aprobadas.

El cuerpo central despliega un bloque informativo reactivo que define la hipótesis fundamental de la medicina de redes: la eficacia terapéutica potencial es inversamente proporcional a la distancia en red entre las dianas farmacológicas y el módulo patológico.

Búsqueda por enfermedad

El usuario selecciona una patología indexada en el catálogo extraído del conjunto de datos multiplex a través de un menú desplegable. Seguidamente, el sistema genera automáticamente un segundo desplegable dinámico para aislar un gen de interés.

El análisis se centra en un único gen seleccionado por el usuario, lo que permite un estudio focalizado de su entorno en el interactoma. Aunque un gen puede mapearse a múltiples identificadores *UniProt* (isoformas proteicas), estas se consideran conjuntamente como una única entidad funcional, manteniendo un enfoque dirigido.


The image shows a dark-themed user interface for selecting a disease and a gene. At the top, there is a label "Selecciona enfermedad" above a dropdown menu that currently displays "Alzheimer's disease". Below this, there is another label "Selecciona un gen" above a second dropdown menu displaying "PSEN1". Underneath the gene selection, a green bar highlights the specific gene identifier "PSEN1 → P49768". At the bottom of the interface, there is a button labeled "Evaluar reposicionamiento para este gen".

Figura 2 Selección de enfermedad

El *frontend* conecta de forma asíncrona con el script externo mediante la función “*convert_gene_list([gene])*”, devolviendo las accesiones *UniProt* asociadas. Si la proteína se encuentra

presente en el interactoma humano, se procede a la ejecución de los resultados y seguidamente el sistema imprime tres salidas consecutivas:

- Tabla de Ranking: Despliega el listado estructurado de los 20 compuestos más próximos ordenados ascendentemente por Z-score.

Drug_Name	Proximidad	Media nula	Desviación nula	Zscore	Pvalor
Nirogacestat	0.8333	2.1558	0.1413	-9.3595	0.001
Fostamatinib	2.0475	2.1578	0.0204	-5.4053	0.001
Tideglusib	1	1.966	0.1812	-5.3303	0.035
Ixazomib	1	1.964	0.2066	-4.6649	0.041
Venetoclax	1	2.034	0.2255	-4.5856	0.01
Carfilzomib	1.5	2.0263	0.1158	-4.5438	0.004
Tioconazole	1	2.034	0.2426	-4.2625	0.014
Bortezomib	1.3333	2.0037	0.1588	-4.222	0.005
Gadopentetic acid	1	1.998	0.2408	-4.1441	0.027
Tetracaine	1.3333	2.426	0.2656	-4.1145	0.001

Figura 3 Resultado tabular

- Grafo de la Subred Contextual: renderiza un *HTML* dinámico donde se observa un diamante rojo (nodo central ficticio del gen), una estrella azul (fármaco central) y los nodos proteicos conectados según su rol biológico mediante un código de colores interactivo.




Figura 4 Visualización subred

- Gráfico de Dispersión Estadístico: un gráfico de dispersión bidimensional interactivo que aísla visualmente en color rojo los 20 fármacos más significativos frente al resto del catálogo en color gris.




Figura 5 Gráfico de dispersión de los 20 fármacos candidatos

- Finalmente cuenta con un botón de descarga directa en formato .csv.

Búsqueda por fármaco

Pestaña diseñada para la búsqueda de sustitutos moleculares o segundas líneas de tratamiento. El usuario interactúa con un buscador desplegable que indexa los nombres de los fármacos en *DrugBank* para encontrar moléculas sustitutas o con perfiles topológicos análogos en el interactoma basado en el solapamiento de dianas.

La interfaz muestra un menú desplegable con el título 'Ibritumomab tiuxetan'. Las opciones visibles son: Ibrutinib, Ibuprofen (seleccionado), Ibuproxam, Ibutilide, Icatibant y Ibuprofen (repetido). Debajo del menú hay un botón con el texto 'Buscar alternativas'.

Figura 6 Selección de fármaco

El sistema recupera de forma unívoca el identificador indexado en la base de datos *DrugBank* correspondiente al compuesto químico seleccionado por el usuario. A partir de este registro, se aísla el conjunto de dianas proteicas humanas asociadas. Se inicializa un algoritmo de búsqueda en anchura multi-fuente que toma como origen simultáneo todos los nodos pertenecientes a las dianas del fármaco

de referencia. Esto calcula de manera exacta las distancias de camino desde las dianas de base hacia el resto de proteínas que constituyen el interactoma global de *BioGRID*.

Top 20 alternativas por Z-score ⇄					
Drug_Name	Proximidad	Media nula	Desviación nula	Zscore	Pvalor
Dexibuprofen	0.3333	1.8682	0.1098	-13.9816	0.001
Fenoprofen	0	1.9108	0.1816	-10.5228	0.001
Indoprofen	0.3333	1.9488	0.1564	-10.3284	0.001
Doconexent	0.6667	1.8654	0.1258	-9.527	0.001
Ketoprofen	0	2.058	0.2165	-9.5072	0.001
Bromfenac	0	2.045	0.2334	-8.7618	0.001
Mefenamic acid	0	2.06	0.2427	-8.4881	0.001
Phenylbutazone	0.3333	2.0563	0.204	-8.4473	0.001
Antipyrine	0	2.0545	0.2465	-8.3335	0.001
Loxoprofen	0	2.0375	0.2446	-8.3289	0.001

Figura 7 Resultados de alternativas del fármaco

El mapa de subred introduce en este caso nodos morados, que identifican proteínas de superposición directa (dianas idénticas compartidas por ambos compuestos), permitiendo al clínico deducir similitudes mecánicas de forma inmediata.




Figura 8 Visualización subred del fármaco candidato




Figura 9 Gráfico de dispersión de los 20 fármacos candidatos

Búsqueda por proteína o gen aislado

El script evalúa si el texto introducido corresponde a un código *UniProt* estándar o a un símbolo genético convencional. Si se trata de un gen, realiza la conversión automática e interseca el listado con los nodos del grafo de *BioGRID*. Si la proteína se encuentra presente en el interactoma humano, se procede a la ejecución del algoritmo y se despliegan los resultados.

Símbolo de interés

PSEN1

Conversión símbolo → Uni

PSEN1 → P49768

Evaluar gen/proteína

Figura 10 Introducción del símbolo

Top 20 fármacos por Z-score					
Drug_Name	Proximidad	Media nula	Desviación nula	Zscore	Pvalor
Nirogacestat	0.8333	2.152	0.1457	-9.0504	0.002
Tideglusib	1	1.97	0.1706	-5.6862	0.0319
Fostatinib	2.0475	2.1581	0.0198	-5.592	0.002
Carfilzomib	1.5	2.0257	0.1003	-5.2401	0.002
Edaravone	1	2.046	0.2364	-4.4247	0.008
Bortezomib	1.3333	1.9947	0.1534	-4.3116	0.002
Tioconazole	1	2.038	0.2461	-4.2181	0.014
Gadopentetic acid	1	1.984	0.2361	-4.1677	0.0339
Venetoclax	1	2.032	0.251	-4.1124	0.018
Ixazomib	1	1.944	0.2385	-3.9587	0.0599

Figura 11 Resultado tabular, búsqueda por proteína




Figura 12 Visualización subred del fármaco candidato




Figura 13 Gráfico de dispersión de los 20 fármacos candidatos

Pestaña de información y calidad de los datos

Esta pestaña funciona como un panel de control técnico que dota de transparencia al sistema, permitiendo al usuario auditar las dimensiones y la cobertura biológica de las redes integradas.

Resumen de Calidad y Métricas de los Datos		
Nodos del Interactoma (Proteínas)	Fármacos únicos (DrugBank)	Enfermedades cargadas
18,017	2,355	910
Interacciones (Aristas BioGRID)	Fármacos Evaluables en Red	Total Genes Únicos de Enfermedad
890,179	2,332	6,152
Cobertura biológica en la red:		
Indicador de Calidad		Valor
Dianas terapéuticas totales en DrugBank		2,277
Dianas terapéuticas cubiertas por el Interactoma		2,216
Porcentaje de cobertura de dianas		97.32%
Densidad de la red (Interactoma)		0.00548
Número medio de interacciones por proteína (Grado medio)		98.82

Figura 14 Resumen de los datos

El módulo concluye citando la procedencia de los recursos de datos abiertos (*Open Data*) empleados (*BioGRID*, *DrugBank* y *MyGene.info*).

Finalmente, expone los metadatos de control institucional que acreditan la autoría y la dirección académica del proyecto dentro del Trabajo de Fin de Máster en Ingeniería Biomédica de la Universidad de Burgos.

Bases de datos utilizadas: • BioGRID: Red de interacciones proteína-proteína humanas (interactoma). • DrugBank: Registro de fármacos y sus correspondientes dianas proteicas mapeadas a identificadores UniProt. • MyGene.info: Módulo de conversión dinámica de Símbolos Genéticos a accesiones UniProt. • Datos provistos en el marco de la asignatura <i>Análisis de Datos de Alta Dimensión y Medicina de Redes</i>.
Información Académica
Trabajo de Fin de Máster (TFM)
Esta aplicación ha sido desarrollada como parte de un Trabajo de Fin de Máster (TFM) en la Universidad de Burgos (UBU).
• Titulación: Máster Universitario en Ingeniería Biomédica. • Autora: Nisrín Fariss Lamine. • Tutores de TFM: ◦ José Ignacio Santos Martín ◦ Virginia Ahedo García

Figura 15 Contenido de la pestaña de Información

Manual del Programador

En este capítulo se incluye la información relacionada con la organización del repositorio [GitHub](#)

Estructura de directorios

La disposición de las carpetas y archivos en el servidor se detalla a continuación:

- Aplicación: presenta el núcleo de la plataforma interactiva web, junto a las imágenes que aparecen en la interfaz. Así mismo también aparecen otros módulos que corresponden a la lógica interna de la aplicación y las librerías necesarias.
- Carpeta de la nueva función, que incorpora el algoritmo final con el que se ha desarrollado el núcleo de la aplicación.
- Tutorías: indicaciones y comentarios del tutor respecto al trabajo en las reuniones establecidas

- Documentación: carpeta que incluye la memoria y los anexos del proyecto
- README.md: archivo de presentación y guía de despliegue del repositorio




Figura 16 Estructura del repositorio

Entorno de desarrollo

La aplicación sido desarrollada bajo el lenguaje de programación Python 3.11. El ecosistema de librerías y dependencias se detalla en la siguiente tabla técnica:

Librerías	Versión	Uso técnico
Streamlit	1.57.0	Framework principal para la arquitectura reactiva web, gestión de estados de sesión y renderizado de componentes de interfaz de usuario (menús, tablas, botones...)
Networkx	3.6.1	Motor de teoría de grafos. Utilizado para modelar el interactoma humano como un grafo, calcular grados de conectividad y estructurar subgrafos.
Pandas	3.0.2	Manipulación, filtrado y estructuración de los datos heterogéneos provenientes de los ficheros de <i>BioGRID</i> , <i>DrugBank</i> .
Numpy	2.2.6	Operaciones matemáticas vectorizadas. Utilizado para el cálculo ágil de la media y desviación estándar de las distribuciones nulas y transformaciones logarítmicas
Pyvis	0.3.2	Renderizado dinámico de redes moleculares. Traduce subgrafos de <i>NetworkX</i> a scripts interactivos.

Plotly	6.8.0	Generación de gráficos analíticos interactivos.
--------	-------	---

Tabla 2 Librerías más empleadas en el desarrollo

Despliegue de la Aplicación

El despliegue de la aplicación se ha realizado mediante la plataforma [Streamlit Cloud](#), un servicio ofrecido por *Streamlit* que permite publicar aplicaciones desarrolladas en *Python* de forma directa desde un repositorio alojado en *GitHub*. Esta plataforma automatiza el proceso de instalación de dependencias, configuración del entorno y ejecución de la aplicación, facilitando su publicación sin necesidad de gestionar infraestructura propia.

En primer lugar, el proyecto ha sido estructurado en un repositorio de *GitHub* que contiene todos los archivos necesarios para su ejecución, incluyendo el script principal de la aplicación, los módulos auxiliares y el archivo *requirements.txt*, en el cual se especifican todas las dependencias necesarias para reproducir el entorno de ejecución. Este archivo es fundamental, ya que el entorno utiliza dicha lista para instalar automáticamente las bibliotecas requeridas.

Una vez verificado el repositorio, se ha procedido a acceder a la plataforma de *Streamlit* mediante la cuenta vinculada a *GitHub*. Desde el panel de control, se ha seleccionado la opción de creación de una nueva aplicación (“*Create app*”), indicando el repositorio correspondiente, la rama principal del proyecto (*main*) y el archivo principal de ejecución de la aplicación, denominado *app.py*. En opciones avanzadas se debe seleccionar la versión de *Python* 3.10 por la estabilidad de las librerías empleadas en el proyecto.

The image shows a web form for deploying a Streamlit application. It has four main sections: 'Repository' with a text input containing 'fariss2/TFM--Identificacion-de-farmacos-mediante-el-analisis-de-proximidad-en-el-interactoma-humano' and a 'Paste GitHub URL' link; 'Branch' with a text input containing 'main'; 'Main file path' with a text input containing 'Aplicacion/app.py'; and 'App URL (optional)' with a text input containing 'bionetdrug' and a '.streamlit.app' suffix. The 'App URL' field is highlighted with a red border.

Figura 17 Panel de control de despliegue

Tras la configuración inicial, se inicia automáticamente el proceso de despliegue. Este proceso consiste en la creación de un entorno virtual en la nube y la ejecución del comando de instalación de dependencias definido en el archivo *requirements.txt*. Durante esta fase, el sistema descarga e instala todas las bibliotecas necesarias para el funcionamiento de la aplicación, resolviendo sus dependencias de forma automática.

Finalmente, la aplicación ha sido desplegada correctamente en *Streamlit*, quedando accesible de forma pública a través de la [URL](#) proporcionada por la plataforma. El sistema ha generado automáticamente

un entorno reproducible que permite la ejecución estable de la aplicación, garantizando su disponibilidad sin necesidad de configuración adicional por parte del usuario final.

Pruebas del sistema

Al tener gran parte de la aplicación, se ha procedido a realizar una prueba del funcionamiento de esta una vez desplegada. Se pasó el enlace directo de la aplicación a usuarios externos, entre ellos el tutor de este trabajo, para comprobar el funcionamiento de las herramientas implementadas.

Instrucciones para la modificación o mejora del proyecto

Para evolucionar la plataforma hacia un sistema predictivo de alta fidelidad fisiológica y viabilidad clínica, se especifican a continuación las pautas de ingeniería de software para implementar las tres mejoras propuestas:

Implementación del Modelado de Efectos Combinados

Objetivo: modificar la lógica para evaluar si la administración conjunta de dos fármacos genera un solapamiento del módulo patológico superior al de las terapias individuales de forma aislada, evitando la redundancia farmacológica.

Diseñar una función en la interfaz que admita una entrada doble de fármacos modificando para permitir un selector múltiple. Se debe modificar la lógica para fusionar los vectores de dianas de ambos compuestos. Posteriormente, se adaptará la rutina de Monte Carlo para realizar simulaciones independientes sobre cada fármaco respetando sus *bins* de grado, calculando finalmente el Z-score del par sinérgico mediante la métrica de separación de Menche. Esta métrica sirve para cuantificar matemáticamente la distancia y el grado de solapamiento entre dos módulos biológicos en el interactoma (4). Se utiliza principalmente para saber si dos enfermedades distintas comparten mecanismos moleculares.

Integración de Redes Específicas por Tejido

Objetivo: restringir el interactoma global de *BioGRID* a un subgrafo funcional que represente exclusivamente las proteínas activas en el tejido diana de la enfermedad.

Se incorporará en la carpeta *data/* el conjunto de datos correspondiente a la expresión génica basal de cada tejido humano que se puede encontrar en fuentes de acceso abierto como [GTEx](#). Posteriormente, se aplicará un filtro por umbral de expresión para extraer únicamente las proteínas activas y se reconstruirá el grafo utilizando una inducción de subgrafo específica para dicho tejido. Al modificar el grafo, las funciones de caminos mínimos subsiguientes ignorarán de forma automática aquellas rutas biológicamente inverosímiles en el tejido diana, recalculando de manera nativa los *bins* de grado sobre la topología de la nueva red específica.

Validación Externa con Conjuntos de Reposicionamiento Conocidos

Objetivo: medir de manera cuantitativa, matemática y objetiva la capacidad predictiva de la aplicación mediante curvas de rendimiento estadístico, demostrando si el algoritmo funciona mejor que una clasificación aleatoria.

Se integrará una base de datos externa de referencia, conectando con la plataforma [DrugCentral](#) o incorporando registros históricamente validados de indicaciones aprobadas y fallidas en ensayos clínicos para las enfermedades analizadas. A partir de este conjunto de validación, se utilizarán las librerías estadísticas del entorno para evaluar la tasa de verdaderos positivos frente a falsos positivos, determinando la sensibilidad del modelo computacional.

Descripción de adquisición y tratamiento de datos

En este apartado se detallará la obtención de datos, desde su descarga hasta su limpieza y curación para emplearlos en la aplicación.

Descripción formal de los datos

La base de datos cruda de *DrugBank* se distribuye en un único archivo maestro en formato XML que consolida información masiva y heterogénea. Debido a que este fichero excede las capacidades de carga directa en memoria RAM mediante métodos de parseo convencionales de árbol completo, se diseñó un pipeline de extracción asíncrono y optimizado en *Python*.

El algoritmo aplica de manera estricta tres filtros jerárquicos de calidad y relevancia biomédica para aislar las interacciones de interés:

- Filtro de Estado de Aprobación (*Approved Drugs*): El sistema inspecciona los subnodos del grupo del compuesto. Si el fármaco no posee explícitamente la etiqueta "*approved*" (fármacos aprobados por agencias reguladoras como la FDA), el elemento es descartado automáticamente y purgado de la memoria. Esto asegura que el ranking final priorice compuestos con perfiles de seguridad clínica consolidados, óptimos para estrategias de reposicionamiento.
- Filtro de Especificidad de Especie (*Humans*): Dentro de las dianas asociadas al fármaco, se conservan de forma exclusiva aquellas interacciones orientadas a proteínas del organismo humano ("*Humans*"), descartando dianas bacterianas, fúngicas o de modelos animales para evitar falsos positivos topológicos en el interactoma.
- Mapeo Moleculares Estándar (*UniProt ID*): Para cada diana humana válida, el algoritmo profundiza hasta el elemento del polipéptido (<polipéptido>) y extrae el atributo de identificación único (id), el cual contiene la accesión de la base de datos internacional *UniProt*.

Los registros que superan con éxito todos los filtros de curación se empaquetan dinámicamente en un *dataframe* relacional bidimensional. El conjunto resultante se exporta y almacena localmente en formato binario y plano, sirviendo como el motor de datos de referencia para el software web.

La red global de interacciones proteína-proteína se construyó a partir del archivo maestro multitable de la base de datos internacional *BioGRID*. Debido al volumen masivo de datos que abarca interacciones de múltiples especies, se diseñó un flujo de curación e ingeniería de datos en Python con el fin de aislar un modelo de red puramente fisiológico, no redundante y optimizado para el cálculo de caminos mínimos.

El archivo crudo se sometió en primera instancia a un filtrado jerárquico multifactorial basado en códigos taxonómicos oficiales y subtipos de validación biológica, conservando únicamente los registros que cumplieran de manera simultánea los siguientes requisitos:

- **Restricción Taxonómica Homóloga:** Se aislaron exclusivamente las interacciones donde tanto el organismo emisor como el receptor pertenecieran estrictamente a la especie humana (*Homo*

sapiens), lo cual se controló indexando el identificador taxonómico de la base de datos del NCBI(9606).


- **Filtro de Evidencia Física:** Se descartaron todas las interacciones de carácter genético o predictivo computacional, garantizando que cada arista cargada en el sistema corresponda a una interacción física demostrada experimentalmente mediante ensayos de laboratorio

Las columnas de accesiones de *Swiss-Prot* en *BioGRID* incluyen múltiples identificadores combinados en una misma celda y separados por barras. Para homogeneizar los nodos del grafo, se aplicó una función que divide la cadena y conserva únicamente el identificador principal de *UniProt*.

Finalmente, el conjunto de datos original de asociaciones entre enfermedades y genes fue provisto en el marco práctico de la asignatura Análisis de Datos de Alta Dimensión y Medicina de Redes. El archivo original contenía un registro individual por cada interacción gen-enfermedad, lo que generaba filas duplicadas para una misma patología. Para optimizar las consultas en la aplicación, se agrupó el conjunto de datos por el nombre de la patología.

Posteriormente se concatenaron todos los símbolos genéticos oficiales asociados a cada enfermedad en una única cadena de caracteres separada por comas. El resultado se exportó al fichero definitivo “disorder_genes.csv”, consolidando así la base de datos estructural que permite a la aplicación delimitar y cargar los módulos patológicos en tiempo real.

Especificación de diseño



Actores y Componentes de la Interfaz

El único actor del sistema es el Usuario (investigador, clínico o desarrollador) , el cual interactúa de forma centralizada con un panel lateral de control y cuatro módulos operacionales:

- Módulo de Búsqueda por Enfermedad: Permite al usuario seleccionar una patología del catálogo general y aislar un gen específico de interés para evaluar hipótesis de reposicionamiento in silico.
- Módulo de Búsqueda por Fármaco: Diseñado para la localización de segundas líneas de tratamiento o sustitutos moleculares mediante un buscador desplegable.
- Módulo de Búsqueda por Proteína o Gen Aislado: Permite la introducción manual de texto libre (símbolos genéticos o accesiones estándar).
- Pestaña de Calidad de Datos: Un panel de control técnico que expone las métricas globales del interactoma, densidad de red...y los metadatos institucionales del TFM.

Capa de Lógica y Algoritmos

Cuando el usuario acciona un botón de evaluación, la interfaz de Streamlit despierta de forma asíncrona los scripts de Python del núcleo de la aplicación:

- Módulo de Conversión Genética: Conecta asíncronamente con la *API* de *MyGene.info* para transformar símbolos convencionales en accesiones de la base de datos internacional *UniProt*.
- Motor de Teoría de Grafos: Carga en memoria el interactoma humano optimizado. Con el algoritmo BFS Multi-fuente ejecuta una búsqueda en anchura tomando como origen simultáneo todas las dianas biológicas del fármaco base para calcular de manera exacta los caminos mínimos en la red de *BioGRID*.
- Desarrollo Matemático del Modelo Nulo: Realiza permutaciones vectorizadas empleando simulaciones de Monte Carlo para obtener la media y desviación estándar nula, calculando finalmente el Z-score y P-valor de proximidad.

Capa de Datos

Para garantizar la viabilidad técnica y evitar parseos lentos en tiempo de ejecución, la aplicación consume tres motores (*BioGrid*, *DrugBank*, Asociación enfermedad-gen) de datos previamente curados y almacenados localmente de forma estricta.

Componentes Visuales

Una vez finalizado el cómputo, el sistema procesa los dataframes mediante librerías especializadas y devuelve tres respuestas dinámicas al usuario:

- Tablas de Ranking: estructuradas con Pandas para mostrar los 20 compuestos candidatos ordenados por significancia estadística (Z-score) con opción de descarga directa en formato .csv.
- Grafos de Subredes Interactivos: scripts HTML interactivos que renderizan el entorno biológico mediante códigos de color.
- Gráficos de Dispersión: gráficos bidimensionales interactivos que aíslan visualmente el comportamiento de los fármacos más significativos frente al resto del catálogo biológico.

Referencias

1. Universidad Alfonso X el Sabio. ¿cuál es el salario de un ingeniero biomédico en España?- uax. [https://www.uax.com/blog/salud/cuanto cobra-ingeniero-biomedico](https://www.uax.com/blog/salud/cuanto-cobra-ingeniero-biomedico), 2025
2. Antonio Luis Gallardo Sánchez-Toledo. ¿cuál es la diferencia entre un sueldo bruto y uno neto? [https://blog.aegon.es/ahorro/ diferencia-entre-salario-bruto-y-neto/](https://blog.aegon.es/ahorro/diferencia-entre-salario-bruto-y-neto/), 2024
3. BOE-A-1996-8930 Real Decreto Legislativo 1/1996, de 12 de abril, por el que se aprueba el texto refundido de la Ley de Propiedad Intelectual, regularizando, aclarando y armonizando las disposiciones legales vigentes sobre la materia. [https://www.boe.es/buscar/act.php?id=BOE A-1996-8930](https://www.boe.es/buscar/act.php?id=BOE-A-1996-8930), 1996
4. Menche, J., Sharma, A., Kitsak, M., Ghiassian, S. D., Vidal, M., Loscalzo, J., & Barabási, A. L. (2015). Disease networks. Uncovering disease-disease relationships through the incomplete interactome. Science (New York, N.Y.), 347(6224), 1257601. <https://doi.org/10.1126/science.1257601>