

PORTADA...

Abstract.....	2
Introducción.....	3
Métodos y Materiales.....	4
Fuentes de datos.....	4
Interactoma.....	4
Modelo Nulo.....	5
Simulación Monte Carlo.....	5
Evaluación estadística.....	5
Modalidades implementadas.....	6
Resultados.....	8
Discusión.....	9
Conclusiones.....	10
lineas futuras: Cachear conversiones gen -> UniProt para evitar llamadas repetidas a MyGene.info.....	10
Referencias.....	11

Abstract

Introducción

La identificación de nuevas indicaciones terapéuticas para fármacos ya existentes ha emergido como una estrategia clave para reducir el elevado coste, tiempo y tasa de fracaso asociados al desarrollo tradicional de medicamentos(1). Se estima que el proceso de desarrollo de un nuevo fármaco puede superar los diez años y requerir inversiones superiores a miles de millones de dólares, con una alta probabilidad de fracaso en fases clínicas avanzadas (2). En este contexto, el reposicionamiento farmacológico ofrece una alternativa eficiente al aprovechar compuestos ya aprobados o en fases avanzadas de desarrollo, cuyo perfil de seguridad es en gran medida conocido(1).

Hoy en día, el desarrollo de la medicina de redes ha proporcionado un marco conceptual innovador para el estudio de enfermedades complejas (3). Este enfoque considera que las enfermedades no son consecuencia de alteraciones aisladas en genes individuales, sino que emergen de alteraciones en módulos específicos dentro del interactoma humano(3). Desde esta perspectiva, tanto las enfermedades como los fármacos pueden representarse como subconjuntos de nodos dentro de una red biológica, lo que permite analizar sus relaciones mediante propiedades topológicas.

Uno de los principios fundamentales de la medicina de redes establece que la proximidad topológica entre las proteínas asociadas a una enfermedad y las dianas de un fármaco puede ser indicativa de su potencial efecto terapéutico (4,5). En concreto, fármacos cuyas dianas se encuentran cercanas a los módulos de enfermedad en el interactoma tienen mayor probabilidad de modular procesos biológicos relevantes para dicha patología (5). Este enfoque ha sido ampliamente utilizado en estudios recientes para la identificación de candidatos a posicionamiento, especialmente en enfermedades complejas donde los mecanismos moleculares no están completamente caracterizados.

Sin embargo, la evaluación de la proximidad en redes biológicas presenta desafíos metodológicos significativos. En particular, la heterogeneidad estructural del interactoma, caracterizado por la presencia de nodos altamente conectados (*hubs*), puede introducir sesgos en las medidas de distancia (3). Para abordar este problema, es necesario emplear modelos nulos que permitan evaluar la significancia estadística de las observaciones, preservando propiedades topológicas clave como el grado de los nodos (6). Este tipo de aproximaciones permite distinguir entre proximidades biológicamente relevantes y aquellas que podrían explicarse por azar.

En este trabajo, se presenta una herramienta computacional para el reposicionamiento de fármacos basada en el análisis de proximidad en el interactoma humano. El sistema integra datos de interacciones proteína-proteína, dianas farmacológicas y genes asociados a enfermedades, y utiliza algoritmos de búsqueda en grafos junto con un modelo nulo basado en simulaciones de Monte Carlo para evaluar la significancia de los resultados. La herramienta se implementa como una aplicación interactiva que permite explorar diferentes escenarios de análisis, incluyendo la evaluación basada en conjuntos de proteínas, fármacos específicos o genes individuales.

El objetivo de este estudio es demostrar el potencial de los enfoques basados en redes para la identificación de candidatos a reposicionamiento farmacológico, proporcionando una plataforma accesible que facilite la generación de hipótesis biológicas y apoye la investigación en medicina traslacional.

Métodos y Materiales

Fuentes de datos

El interactoma humano se construyó a partir de interacciones proteína-proteína obtenidas de la base de datos *BioGRID*, que recoge interacciones experimentales validadas(7). Estas interacciones se integraron en una red global no dirigida, asumiendo que la interacción es bidireccional desde el punto de vista funcional.

Las relaciones fármaco-diana se obtuvieron de *DrugBank*, una base de datos ampliamente utilizada que integra información farmacológica y molecular (8). Cada fármaco se asoció a uno o varios identificadores *UniProt* correspondientes a sus proteínas diana.

Los genes asociados a enfermedades se obtuvieron del estudio de “*The multiplex network of human diseases*”(9), en el que se construye una red multiplex que integra distintas capas de información biológica y clínica para caracterizar las relaciones entre patologías humanas. Este recurso proporciona asociaciones gen-enfermedad curadas y validadas, derivadas de la integración de múltiples fuentes biomédicas.

A partir de este conjunto de datos, se extrajeron los genes asociados a cada enfermedad y se procedió a su mapeo a identificadores *UniProt* de manera simultánea que se trabaja con la enfermedad en la aplicación, con el objetivo de garantizar la compatibilidad con el interactoma proteico utilizado en este estudio. Este proceso de conversión es esencial para integrar información heterogénea dentro de un mismo marco de análisis basado en redes, permitiendo representar tanto enfermedades como fármacos en términos de proteínas dentro del interactoma.

Interactoma

El sistema biológico obtenido de *BioGRID* se modeló como un grafo no dirigido y no ponderado $G=(V,E)$, donde:

- V : representa el conjunto de proteínas
- E : representa las interacciones entre proteínas

La elección de un grafo no ponderado implica que todas las interacciones se consideran equivalentes, independientemente de su fuerza o tipo experimental. Aunque esta simplificación puede perder información cuantitativa, es una práctica habitual en estudios de medicina de redes debido a la heterogeneidad de las fuentes de datos.

El grafo fue implementado utilizando la librería *NetworkX*(10), que permite la manipulación eficiente de estructuras de red y la aplicación de algoritmos clásicos de teoría de grafos.

Dentro del interactoma, tanto enfermedades como fármacos se encuentran como nodos formando parte del grafo implementado.

- Modulo de enfermedad: $S = \{s_1, s_2, \dots, s_m\}$
- Dianas de un fármaco: $T = \{t_1, t_2, \dots, t_m\}$

Esta representación permite estudiar la relación entre ambos conjuntos en términos de proximidad topológica. Desde el punto de vista biológico, se asume que las enfermedades alteran regiones específicas de la red, mientras que los fármacos ejercen su efecto al interactuar con nodos dentro o próximos a dichas regiones(5).

Para evaluar la proximidad entre un conjunto de proteínas de enfermedad S y las dianas de un fármaco T, se calculó la distancia mínima en la red entre ambos conjuntos. En lugar de calcular distancias individuales entre todos los pares (s,t), se utilizó un algoritmo de búsqueda en anchura multi-fuente (*multi-source BFS*), que permite calcular de forma eficiente la distancia mínima desde cualquier nodo de la enfermedad a todos los nodos del grafo. La distancia de un nodo v al conjunto S se define como:

$$d(v, S) = \min_{s \in S} d(v, s)$$

Con estas distancias se define la proximidad entre enfermedad y el fármaco de la siguiente manera:

$$d(S, T) = \frac{1}{|T|} \sum_{t \in T} d(t, S)$$

Esta medida captura la cercanía promedio de las dianas del fármaco al módulo de enfermedad, que cuanto más próximas estén menor será esta distancia.

Modelo Nulo

Una de las principales dificultades en el análisis de redes biológicas es la presencia de nodos altamente conectados (*hubs*), que presentan distancias cortas hacia la mayoría de nodos del grafo. Esto puede introducir sesgos en la interpretación de la proximidad(6).

Para corregir este efecto, se diseñó un modelo nulo que preserva la distribución de grados de las proteínas. En lugar de seleccionar nodos aleatorios de forma uniforme con propiedades topológicas similares se agrupan los nodos en *bins* según su grado. Este enfoque permite controlar el sesgo estructural de la red y es consistente con metodologías establecidas en el análisis de redes biológicas.

Simulación Monte Carlo

Para cada fármaco, se generaron múltiples conjuntos aleatorios de dianas siguiendo el modelo nulo descrito. Para cada conjunto aleatorio, se calculó la distancia, obteniendo así una distribución empírica de referencia. La utilización de esta simulación permite estimar la variabilidad esperada bajo condiciones aleatorias y evaluar la robustez de los resultados observados.

Evaluación estadística

La significancia de la proximidad entre enfermedad y fármaco se evaluó mediante dos métricas:

Z – score

$$Z = \frac{d_{obs} - \mu}{\sigma}$$

- d_{obs} : distancia observada
- μ : media de distancias aleatorias
- σ : desviación estándar

Un valor negativo indica que el fármaco está más próximo al módulo de enfermedad de lo esperado por azar.

p – valor

$$p = \frac{1 + \#\{d_{rand} \leq d_{obs}\}}{N+1}$$

- $\#\{d_{rand} \leq d_{obs}\}$ Es el número de distancias del conjunto de las N realizaciones tales que son menores o iguales a la distancia observada. Se suma un 1 para evitar valores 0.

Este p-valor responde a la proporción de muestras aleatorias están tan cerca o más cerca que el fármaco real, si la hipótesis del modelo nulo es cierta; y puede interpretarse como un p-valor, cuanto menor p-valor más seguridad en rechazar la hipótesis de que nuestra distancia observada es un dato puramente aleatorio.

De esta manera los resultados se ordenaron por Z -score y p-Valor para priorizar aquellos fármacos con una proximidad significativa, lo que sugiere una posible interacción funcional con el módulo de enfermedad.

Modalidades implementadas

La primera funcionalidad de la aplicación permite, dado un conjunto de proteínas asociadas a una enfermedad, identificar y priorizar fármacos potencialmente relevantes en función de su proximidad en el interactoma.

Dada una enfermedad D , definida por un conjunto de proteínas S_D . Para cada fármaco candidato F con dianas T se calcula:

$$d_{obs}(F, D) = d(T, S_D)$$

Después se generan las muestras aleatorias de las dianas del fármaco y se calcula la distancia:

$$d_{rand} = d(T_{rand}, S_D)$$

El Z-score vendrá dado de la siguiente manera:

$$z(F, D) = \frac{d_{obs}(F, D) - \mu_{rand}(F, D)}{\sigma_{rand}(F, D)}$$

De la misma manera, dado un fármaco de referencia F_q con dianas T_q , se busca un fármaco cuyas dianas estén próximas de las del de referencia.

Para cada fármaco candidato F_j se calcula:

$$d_{obs}(F_j, F_q) = d(T_j, T_q)$$

Después se repite el mismo proceso mencionado anteriormente. Se fija el conjunto T_q y se aleatorizan las dianas del fármaco candidato T_j , y el Z-score vendrá dado de la siguiente manera:

$$z(F_j, F_q) = \frac{d_{obs}(F_j, F_q) - \mu_{rand}(F_j, F_q)}{\sigma_{rand}(F_j, F_q)}$$

Implementación computacional

La metodología fue implementada en *Python* utilizando las siguientes librerías:

- *NetworkX* para el análisis de grafos
- *NumPy* para cálculos estadísticos
- *Streamlit* para el desarrollo de la interfaz interactiva
- *PyVis* para la visualización de redes

La aplicación permite realizar análisis desde tres perspectivas (gen, enfermedad o fármaco), manteniendo el mismo marco metodológico basado en proximidad en red.

La implementación mediante Streamlit permite una interfaz sencilla e intuitiva, accesible desde el navegador, lo que facilita su uso por perfiles no técnicos como farmacéuticos o profesionales clínicos.

Resultados


Se ha desarrollado una aplicación web interactiva que implementa el modelo de proximidad en redes descrito en la sección de Métodos. La aplicación permite al usuario introducir distintos tipos de entrada (enfermedad, proteína o fármaco) y obtener resultados interpretables en tiempo real.

La interfaz presenta tres modos principales de análisis:

- Entrada por enfermedad o proteína : permite identificar fármacos candidatos cuyas dianas se encuentran próximas al módulo de la proteína o enfermedad en el interactoma.
- Entrada por fármaco: permite identificar fármacos alternativos basados en la proximidad entre sus dianas.

Los resultados se muestran en forma de tablas ordenadas por z-score, junto con métricas adicionales como la distancia observada y el valor empírico. Esta representación facilita la priorización de candidatos por parte del usuario.

Por otro lado también permite la descarga del resultado para análisis posteriores



Drug_Name	DrugBank_ID	Proximidad	Zscore	↑ Pvalor
Arteminol	DB11638	1.3038	-5.3452	0.001
Adenosine phosphate	DB00131	1.5	-3.9683	0.001
Daprodustat	DB11682	1	-3.9121	0.001
Rutin	DB01698	1	-3.8902	0.002

Además de los resultados tabulares, la aplicación incluye una funcionalidad de visualización interactiva de subredes relevantes del interactoma.

En estas visualizaciones:


Las proteínas asociadas a la enfermedad se representan en color rojo.

Las dianas del fármaco se representan en color azul.


Farmaco candidato en estrella

Los nodos vecinos se muestran en gris.

Esto permite observar de forma intuitiva la proximidad topológica entre los distintos elementos y comprender mejor los resultados obtenidos.



interpretacion



Priorización de fármacos para una enfermedad o proteína

Al seleccionar una enfermedad o proteína, la aplicación genera un ranking de fármacos ordenados por su z-score. Los fármacos con valores más negativos se consideran más próximos al módulo de enfermedad de lo esperado por azar.

Los resultados muestran que el modelo es capaz de identificar fármacos con una proximidad significativa en la red, lo que sugiere su posible relevancia terapéutica.

Identificación de fármacos alternativos

En el caso de introducir un fármaco como entrada, la aplicación permite identificar otros fármacos con perfiles de dianas similares en términos de proximidad en la red.

Los resultados se presentan nuevamente en forma de ranking, lo que permite explorar posibles alternativas terapéuticas basadas en la estructura del interactoma.

Discusión

Los resultados obtenidos deben interpretarse como una herramienta de priorización basada en propiedades topológicas de la red. Un z-score negativo indica que las dianas de un fármaco están más próximas al módulo de referencia de lo esperado por azar, pero no implica una validación clínica directa.

Por tanto, estos resultados deben complementarse con información adicional, como evidencia experimental, mecanismos de acción o datos clínicos.

Conclusiones

lineas futuras: Cachear conversiones gen -> UniProt para evitar llamadas repetidas a MyGene.info.

Referencias

1. Pushpakom, S., Iorio, F., Eyers, P. A., Escott, K. J., Hopper, S., Wells, A., Doig, A., Williams, T., Latimer, J., McNamee, C., Norris, A., Sanseau, P., Cavalla, D., & Pirmohamed, M. (2019). Drug repurposing: progress, challenges and recommendations. *Nature reviews. Drug discovery*, 18(1), 41–58. <https://doi.org/10.1038/nrd.2018.168>
2. DiMasi, J. A., Grabowski, H. G., & Hansen, R. W. (2016). Innovation in the pharmaceutical industry: New estimates of R&D costs. *Journal of health economics*, 47, 20–33. <https://doi.org/10.1016/j.jhealeco.2016.01.012>
3. Barabási, A. L., Gulbahce, N., & Loscalzo, J. (2011). Network medicine: a network-based approach to human disease. *Nature reviews. Genetics*, 12(1), 56–68. <https://doi.org/10.1038/nrg2918>
4. Menche, J., Sharma, A., Kitsak, M., Ghiassian, S. D., Vidal, M., Loscalzo, J., & Barabási, A. L. (2015). Disease networks. Uncovering disease-disease relationships through the incomplete interactome. *Science (New York, N.Y.)*, 347(6224), 1257601. <https://doi.org/10.1126/science.1257601>
5. Guney, E., Menche, J., Vidal, M., & Barabási, A. L. (2016). Network-based in silico drug efficacy screening. *Nature communications*, 7, 10331. <https://doi.org/10.1038/ncomms10331>
6. Maslov, S., & Sneppen, K. (2002). Specificity and stability in topology of protein networks. *Science (New York, N.Y.)*, 296(5569), 910–913. <https://doi.org/10.1126/science.1065103>
7. Stark, C., Breitkreutz, B. J., Reguly, T., Boucher, L., Breitkreutz, A., & Tyers, M. (2006). BioGRID: a general repository for interaction datasets. *Nucleic acids research*, 34(Database issue), D535–D539. <https://doi.org/10.1093/nar/gkj109>
8. Knox, C., Wilson, M., Klinger, C. M., Franklin, M., Oler, E., Wilson, A., Pon, A., Cox, J., Chin, N. E. L., Strawbridge, S. A., Garcia-Patino, M., Kruger, R., Sivakumaran, A., Sanford, S., Doshi, R., Khetarpal, N., Fatokun, O., Doucet, D., Zubkowski, A., Rayat, D. Y., ... Wishart, D. S. (2024). DrugBank 6.0: the DrugBank Knowledgebase for 2024. *Nucleic acids research*, 52(D1), D1265–D1275. <https://doi.org/10.1093/nar/gkad976>
9. Halu, A., De Domenico, M., Arenas, A. *et al.* The multiplex network of human diseases. *npj Syst Biol Appl* 5, 15 (2019). <https://doi.org/10.1038/s41540-019-0092-5>
10. Aric A. Hagberg, Daniel A. Schult and Pieter J. Swart, “Exploring network structure, dynamics, and function using NetworkX”, in Proceedings of the 7th Python in Science Conference (SciPy2008), Gael Varoquaux, Travis Vaught, and Jarrod Millman (Eds), (Pasadena, CA USA), pp. 11–15, Aug 2008